

BIOFIN 열린재정 · NLP 프로토타입

예산 문서 자동 분류 프로토타입 개발

텍스트 분류 기반 · HWP/PDF → 16개 분야 자동 분류

소스	전체 문서	모델	분야	ACCURACY
HWP / PDF	9,108개	KLUE-BERT	15개	95.6 %

ARCHITECTURE

전체 파이프라인



DATA

입력 데이터 & 레이블

9,108

전체 문서 수

8,294

텍스트 추출 성공
(814건 실패)

16

분야 수

추출 성공 기준 파일 구성

HWP
8,194
98.8%

PDF
100
1.2%

레이블 출처 · workfile.xlsx → 분야명 컬럼

공공질서및안전

과학기술

교육

교통및물류

국방

국토및지역개발

농림수산

문화 및 관광

보건

사회복지

산업·중소기업 및 에너지

일반·지방행정

통신

통일외교

환경

예비바

EXTRACTION FAILURES


텍스트 추출 실패 유형 — 814건



파일 없음


missing_file

xlsx에 사업명은 있으나 파일이 존재하지 않는
경우



empty_text

파일은 존재하나 텍스트 레이어가 없는 경우
(빈 페이지 등)



extract_error

파일 파싱 중 오류 발생 (손상된 파일, 지원하지
않는 형식 등)

문서 전처리 — 파일 형태별 처리

HWP

내부 구조 직접 접근

HWP 파일은 내부가 폴더 구조로 나뉘어 있고, 본문은 BodyText 영역에 압축된 형태로 저장됨

한글 프로그램 없이 추출

OleFile 라이브러리로 파일을 직접 열어 BodyText만 꺼낸 뒤, zlib 압축을 해제해 텍스트로 복원

표 내 텍스트 포함

표 셀 안의 내용도 BodyText 구조 안에 포함되어 함께 추출됨 (표의 행·열 구조 자체는 미반영)

PDF

페이지별 텍스트 레이어 추출

pypdf 라이브러리로 각 페이지에 삽입된 텍스트 레이어를 순서대로 읽어 하나의 문자열로 합산


스캔 PDF가 들어오면 추출 불가 가능

이미지 기반 스캔 PDF는 텍스트 레이어가 없을 수 있어, 이런 경우에는 텍스트 추출이 되지 않아 empty_text로 처리될 수 있음

HWP EXTRACTION EXAMPLE

한글 문서는 표와 배치가 있는 화면 그대로 저장되어 있어도, 추출 후에는 BodyText 기반의 줄 단위 평문으로 정리됩니다.

OleFile → BodyText 추출 → 평문 변환



원본 HWP 문서



OLEFILE EXTRACTED TEXT

사 업 명
입법활동지원 (1031-300)

1. 사업 코드 정보
일반회계 / 국회 / 기획조정실 / 010 / 011
일반지방행정 / 입법및선거관리
...

4. 사업목적
한시적으로 청년의 취업을 촉진하고 ...

텍스트 정형화 전략

⚠ 핵심 문제 · 레이블 누수 (LABEL LEAKAGE)

예산 문서 본문에 **분야명이 직접 노출**되어 분류기가 실제 패턴 대신 키워드를 암기할 위험

- 1 "사업목적" 이후 **핵심 본문 구간 사용** — 앞단 헤더 제거, 본문 중심 정리
- 2 **헤더/메타데이터 마스킹** — 담당자·사업코드 등 식별 정보 제거
- 3 **사업목적 구간 탐지 실패 시 전체 텍스트 사용** — 정보 손실 방지

HWP EXAMPLE

앞부분의 코드 정보·지원형태·예산 총괄표는 제거하고, **사업목적 이후 본문**을 모델 입력에 사용

본문 구간 사용

날리는 부분

사 업 명						
임명활동지원(1031-300)						
1. 사업 코드 정보						
구분	회계	소관	실국(기관)	계정	분야	부분
코드	일반회계	국회	기획조정실		010	011

사용한 부분

구분	프로그램		단위사업		세부사업	
코드	1000		3031		300	
명칭	의정활동지원		의정지원		입법활동지원	
2. 사업 지원 형태 및 지원율						
직접	중자	중연	보조	융자	국고보조율(%)	융자율 (%)
○						

표시 예시: 문서 상단의 메타정보는 제거하고, **4. 사업목적**부터 시작하는 핵심 본문 구간을 사용합니다.

데이터 분할 — 누수 방지

🔴 문제 • 그룹 중복 누수

같은 사업 문서가 train/test에 모두 포함되면 성능 과대평가

- ▶ **해결** : 부처명 + 세부사업명 기준 그룹화 → 같은 그룹은 반드시 같은 split 배정
- ▶ **라벨 정리** : 최소 샘플 3개 미만(예비비) 분야 제외 → 최종 **15개 분야**

비슷한 사업 문서 예시

같은 라벨 안에서도 같은 부처와 세부사업명을 가진 문서는 내용이 매우 유사할 수 있어, train/test에 나뉘면 성능이 과대평가될 수 있음

한 그룹으로 묶음

5731_... hwp
농림축산식품부
비통화금융기관예치

5733_... hwp
농림축산식품부
비통화금융기관예치

5735_... hwp
농림축산식품부
비통화금융기관예치

예시 그룹 키: 농림축산식품부 + 비통화금융기관예치. 이 문서들이 train/test로 나뉘면 모델이 사실상 비슷한 사업 설명을 미리 보고 평가받게 되므로, 같은 split으로 묶어 배정함.

6,634

Train

832

Validation

827

Test

모델 — KLUE/BERT-base

- ▶ **모델** : KLUE/BERT-base — 한국어 특화 BERT
- ▶ **입력** : 전체 문장 → [CLS] 토큰으로 문서 표현
- ▶ **출력** : 15개 분야 softmax 분류
- ▶ **방식** : 문서 수준 텍스트 분류 (NER 아님)
- ▶ **컨텍스트** : 512 토큰 전체 문맥 활용

HYPERPARAMETERS			
Learning Rate			2e-5
Batch Size			8
Epochs			3
Max Tokens			512
Classes			15

RESULTS

결과

96.3%

Test Accuracy · Macro F1: 0.956

- ▶ 모든 **15개 분야** 에서 F1 Score 0.956 달성
- ▶ **해석** : 레이블과 문서 내용의 강한 연관성 → 과적합 가능성 또는 실제 패턴 명확
- ▶ **향후 검증** : 실제 비분류 문서 적용 시 성능 재평가 필요

주의: 본 테스트셋은 정답 레이블을 비교적 쉽게 구분할 수 있는 구조여서 100% 성능이 나타났을 가능성이 있으며, 실제 수행 데이터에서는 성능이 달라질 수 있음

FUTURE WORK

한계 & 향후 과제



표 구조 해석 미적용

현재는 텍스트 레이어만 추출. 표 내 수치·구조 데이터를 위한 파서 고도화 필요



전처리 고도화

전처리 도구와 청킹 방법을 추가로 학습하고, 문서 형태별 전처리 방식을 더 고도화할 예정

BIOFIN 열린재정 · NLP 프로토타입

감사합니다.

질문이나 의견 주시면 이어서 설명드리겠습니다.