


BIOFIN 예산분류 실험 보고 · 진행사항 보고

BIOFIN 분류 모델 구축 및 입출력 파이프라인 검증



예산자료 입력부터 모델 학습 및 결과 출력까지 전체 과정의 정상 작동 여부를 확인

BIOFIN RESEARCH

01 / 14

분류 과제

**관련 없음 및 BIOFIN 9개 범주 중 하나를
출력하도록 구성**

0. 관련 없음

보호구역

생태계 복원

유전자원

지속가능한 이용

오염관리

조사·교육·지식

녹색경제

정책개발계획

기타 관련 활동

각 예산사업에 대해 0번 또는 BIOFIN 9개 범주 중 하나를 출력하도록 분류 설정

데이터 입력

예산사업(42,749건) 및 사업설명서 (2,703개)를 입력자료로 사용

예산 CSV (2019 ~ 2023)

2019

2020

2021

2022

2023

사업설명 문서

HWP 2,614개

HWPX 89개


42,749

총 예산 행

2019~2023년 예산 CSV 5개와 HWP·HWPX 사업설명자료를 입력자료로 사용

예산 데이터 구조


한 행의 13개 예산 항목을 모델 입력으로 사용



예산 항목은 입력으로 사용하고, biofin_category는 학습·검증을 위한 임시 기준 라벨로
사용

문장 변환

CSV 한 행을 열 이름이 포함된 문장으로 변환



열 이름과 값을 연결해 모델이 각 항목의 의미를 구분할 수 있도록 변환

문서 결합 방식

**사업설명 본문을 연결하고 미연결 사업
은 예산정보만 사용**

문서 있음

예산정보 + 사업설명 본문

2,136건

문서 없음

예산정보만

40,470건


42,606

총 모델 입력 건수

본문 포함 2,136건과 예산정보만 포함한 40,470건을 합쳐 총 42,606건의 모델 입력을 구성

학습·검증 분할

동일 사업이 학습·검증 데이터에 중복되지 않도록 분리



34,085
학습

8,521
검증

0건

중복 사업 그룹

소관명과 세부사업명이 같은 자료는 한쪽 데이터에만 배치했으며, 학습·검증 간 중복 사업 그룹은 0건이었음.

데이터 불균형

데이터 불균형 완화를 위해 균형 표본추출을 적용

40,447

0번 (관련 없음)


17

8번 (가장 적은 범주)

매 학습 회차마다 범주별 100건을 추출했음. 표본이 100건보다 적은 범주는 복원추출 (반복 샘플링)로 채우고, 0번처럼 표본이 넘치는 범주는 일부만 추출해 모든 범주가 균형 있게 학습에 포함되도록 구성

모델 구조


**긴 입력을 512토큰 단위로 분할해 모델
에 전달**



입력을 겹치는 조각으로 나눈 뒤 KLUE/RoBERTa와 Attention을 이용해 최종 범주를 출력하도록 구성했음.

학습 진행 결과

모델 학습 5회 정상 진행 및 최적 체크포인트 저장 완료



회차별 학습 로그와 검증 지표가 정상적으로 생성되었으며, 4회차 모델을 최종 체크포인트로 저장했음.

검증 지표 산출

검증 지표 정상 산출 및 저장 완료



정확도 계산 : 92.36%



손실(Loss) 계산·정상 산출



Macro F1 계산 · 0.490

정확도, 손실과 F1 지표의 계산 기능이 정상 작동했음. 단, 임시 라벨 기준 결과이므로 실제 모델 성능 판단은 불가함.

예측 결과 저장

검증 데이터 8,521건의 개별 예측 결과를 저장

사업 ID

기준 라벨

예측 범주

모델 점수

8,521건

검증 데이터 예측 결과



valid_predictions.csv 저장 완료

사업별 기준 라벨, 예측 범주와 모델 점수를 valid_predictions.csv로 정상 출력 완료

범주별 평가 · ATTENTION 분석

범주별 평가 및 Attention 분석 결과를 함께 생성

범주	F1	검증 건수
● 0 관련없음	0.968	8,089
● 1 보호구역	0.377	32
● 2 생태계 복원	0.536	34
● 3 유전자원	1.000	5 ▲ 표본 부족
● 4 지속가능한 이용	0.386	59
● 5 오염관리	0.522	69
● 6 조사·교육·지식	0.287	42
● 7 녹색경제	0.574	100
● 8 정책·개발계획	0.000	3 ▲ 표본 부족
● 9 기타 관련 활동	0.249	88

✓ 범주별 평가표

✓ 혼동행렬

✓ 문서 조각별 Attention 가중치

범주별 평가표, 혼동행렬과 문서 조각별 Attention 가중치를 분석용 결과물로 저장

예산자료 입력부터 예측 결과 저장까지 전체 처리 과정의 정상 작동 확인.
실제 성능 평가는 전문가 검증 라벨 구축 후 가능.

- 전문가 검증 라벨 구축 필요
- 라벨 불일치 및 희소 범주 보완 필요
- 고정된 시험 데이터를 활용한 재평가 필요
- 사업설명자료가 있는 데이터만 활용하여 테스트 할 예정