


BIOFIN 분류 파이프라인 검증 보고

사업설명자료 기반 BIOFIN 분류 파이프라인 검증

문서 선정부터 학습·예측·분석 결과 저장까지 전체 처리 결과



사업설명 본문이 있는 자료만 사업 단위로 나누어 학습·검증에 사용

BIOFIN RESEARCH

01 / 14

BIOFIN 10개 분류 범주

관련 없음 1개 범주와 생물다양성 관련 9개 범주



biofin_category는 예산사업에 부여된 임시 기준 라벨

입력자료

사업설명자료 2,703개를 분류 모델의 입력자료로 사용



사업설명 본문 추출이 완료된 자료만 최종 학습에 사용

문서 처리 결과

사업설명자료 2,703개 중 2,477건 처리 완료

학습 사용	2,477건
복수 라벨로 제외	225건
본문 추출 실패	1건
$2,477 + 225 + 1 = 2,703$	

복수 라벨 제외 225건 · 하나의 문서에 여러 라벨 행이 연결되어 단일 임시 라벨 확정 불가

학습 사용 2,477건 중 사업명 정확 일치 2,276건, 포함 일치 201건

최종 학습자료

본문 추출 완료 문서 2,477건으로 학습자료 구성

2,477건

최종 사용 자료

100%

사업설명 문서



1,981건

학습


496건

검증

사업설명자료가 없는 예산사업은 학습 대상에서 제외

범주별 데이터 구성


10개 범주별 학습자료 구성



범주별 자료 수 차이가 존재하는 임시 라벨 데이터

학습·검증 분할

동일 사업의 학습·검증 중복 방지



1,981건

학습 · 727개 그룹

496건

검증 · 182개 그룹

0개

중복 그룹

소관명과 세부사업명이 같은 자료를 하나의 사업 그룹으로 구성 · 동일 사업의 여러 연도 자료를 학습과 검증에 분산하지 않는 구조

모델 처리 구조

긴 사업설명자료의 문서 조각 단위 처리



긴 문서를 여러 조각으로 나누고 각 조각의 정보를 결합한 최종 범주 출력

학습 실행 결과

5회 모델 학습 및 체크포인트 저장 완료




회차별 검증 지표 정상 기록 · 회차별 학습·검증 로그, 최종 모델, 토크나이저 저장 완료

임시 라벨 기반 산출값으로 모델 성능 판단 제외

검증 지표

검증 지표 4종 정상 산출



검증 손실, 정확도 및 F1 계산 과정 정상 작동

임시 라벨 기준 결과로 실제 분류 성능 판단 제외

개별 예측 결과

검증자료 496건의 개별 예측 결과 저장

연도

소관명

세부사업명

실제 임시 라벨

예측 라벨

예측 확률

연도	소관명	세부사업명	실제 임시 라벨	예측 라벨	예측 확률
2021	환경부	생물다양성협약 대응	8 정책·개발계획	8 정책·개발계획	0.998

검증자료 입력부터 범주 예측 및 파일 저장까지 정상 처리

평가 결과물

범주별 평가표 및 혼동행렬 생성

범주별 평가표

범주	P	R	F1	건수
● 0 관련없음	0.444	0.238	0.310	84
● 1 보호구역	0.455	0.500	0.476	30
● 2 생태계 복원	0.421	0.516	0.464	31
● 3 유전자원	1.000	1.000	1.000	5 ▲ 표본 부족
● 4 지속가능한 이용	0.481	0.655	0.555	58
● 5 오염관리	0.706	0.787	0.744	61
● 6 조사·교육·지식	0.192	0.225	0.207	40
● 7 녹색경제	0.535	0.697	0.605	99
● 8 정책·개발계획	0.333	1.000	0.500	3 ▲ 표본 부족
● 9 기타 관련 활동	0.488	0.247	0.328	85

혼동행렬



세로축 실제 임시 라벨 · 가로축 예측 라벨 · 대각선 라벨 일치

평가 산출물 생성 여부 확인 목적 · 임시 라벨 기반 결과로 오분류 원인 및 모델 성능 해석 제외

ATTENTION 결과


문서 조각별 Attention 분석 결과 생성

496건

검증 문서

3,003개

분할된 텍스트 구간



2021년 · 환경부 · 생물다양성협약 대응 문서 4개 조각의 Attention 가중치 · 범주 예측에 상대적으로 크게 반영된 문서 구간 확인 가능

Attention 가중치는 모델 판단의 참고 정보이며 인과적 설명 근거로 해석하지 않음

사업설명자료 선정부터 모델 학습과 분석 결과 저장까지 전체 처리 과정 완료.
현재 결과는 임시 라벨 기반의 파이프라인 검증 결과

- 본문 추출
- 학습·검증 그룹 분할
- 검증 지표 산출
- 평가표·혼동행렬 생성

- 전문가 검증 라벨 구축
- 복수 라벨 문서 225건 검토
- 검증 라벨 기반 모델 성능 평가